

# Narrative Pipeline

サンプルデータ

図解・数式補助

ニュース記事から Narrative Intensity、Narrative Momentum 投資戦略までを  
サンプルデータで視覚化する



articles → families →  $I_{n,t}$  →  $w_t$

目的: プログラムの実装詳細ではなく、処理の目的・定式化・数値の読み方を視覚的に説明する。

# 全体設計： 3 本の Notebook が処理する変換

「発見」「計測」「運用」を分けると、各プログラムの目的が明確になる

## ① 発見

未知の出来事のまとめ

$\{a_i\} \rightarrow \{F_k\}$

記事間の線の強さを測り、安定して密につながる島を family とする。

## ② 計測

固定 Narrative の時系列

$a_i \rightarrow y_{in}, p_i^-, p_i^+ \rightarrow I_{n,t}$

固定 Registry へ分類し、全ニュース流量に対する比率として Intensity 化する。

## ③ 運用

Intensity 変化を資産で取引

$I_{n,t} \rightarrow S_{n,t}, \beta_{in,t} \rightarrow w_t$


Narrative Momentum signal で選び、beta ・ mapping でポートフォリオ化する。

### 視覚化の軸

記事カード・ネットワーク・ヒートマップ・ランキング・beta 散布図・ポートフォリオ比較を順に使う。

# 01：サンプル記事を「出来事のまとまり」として見る

記事カードを時系列上に置き、人間が見ても分かる 3 つの話題を作る




# 01：記事間 affinity を数値化し、疎なネットワークへ

意味・語彙・entity・時間差を統合して、記事間の「線の太さ」を定義する


$$A_{ij} = C_{ij} \times [(1 - \lambda_t) + \lambda_t \exp(-\Delta t_{ij}/\tau)]$$

例：日銀 A- 日銀 B



$C = (0.90 + 0.60 + 0.80) / 3 = 0.767$   
 $\Delta t = 3 \text{ 日}, \lambda = 0.5, \tau = 7 \rightarrow A \approx 0.633$

Affinity matrix



強い edge だけを残す



日銀 family



原油 family




noise

全ペアを dense に扱わず、semantic kNN・entity index・time window から候補 edge だけを作る。

# 01： Consensus で「安定して同じ島になる関係」を残す

パラメータや seed を変えても共起する edge を信頼する

## 同じ family への共割当 $q_{ij}$



$$q = 7/8 = 0.875$$

## デモ family 品質



Separation = 内部 affinity 平均 - 外部 affinity 平均

## 分類結果の読み方



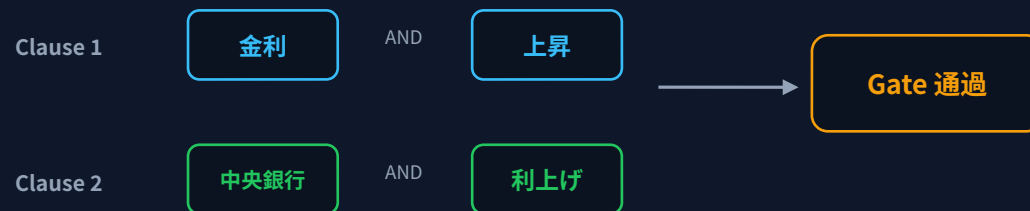
## 02：固定 Registry に対する multi-label 分類

固定 Narrative の定義を使い、記事を監査可能なルールで分類する

### 分類ファネル（デモ値）



### DNF gate：AND 条件の OR



$$\text{Score} = \text{group 合計} + \text{proximity} - \text{exclusion}$$

Rule だけで hard match を決定し、semantic-only candidate は自動昇格しない。

### Registry 仕様




監査性: matched terms / clauses / exclusions / conflict resolution を保存

## 02： Narrative Intensity は「全ニュース流量に占める比率」

Coverage と Sentiment を面積で理解する

説明用：全ニュース 100 件、Narrative 該当 12 件




● Negative 7 ● Positive 3 ● Neutral 2 ● 非該当 88

$$\text{Coverage} = 12 / 100 = 12\%$$

$$I^- = 7 / 100 = 7\%$$

$$I^+ = 3 / 100 = 3\%$$

分解：話題量 × トーン



Negative 7% / Positive 3% / Neutral 2%

$$I^- = \text{Coverage} \times \text{Pr}(\text{Negative} \mid \text{Narrative})$$

Notebook 入力例：NARR\_01 の daily aggregate では coverage=0.119、negative=0.052、positive=0.055。

注意

$I^+I^-$  は net sentiment ではない。  
net を作るなら  $I^+ - I^-$ 。

# 02→03： Intensity の変化を Narrative Momentum signal にする

直近 J か月平均 – その前 J か月平均で、上昇 Narrative を選ぶ


$$S_{n,t}^{\wedge}(J) = \text{mean}(I_{n,t-J+1:t}) - \text{mean}(I_{n,t-2J+1:t-J})$$

例： global\_growth, J=6



$$\text{signal} = +0.122$$

最新 J=6 ranking (デモ)



Rising は signal 上位、Declining は下位。標準列が negative\_intensity\_hard の場合、上昇は「negative attention の上昇」を意味する。

J={1,3,6,9,12} の複数 lookback で比較可能。




# 03 : Narrative beta は「Intensity 変化への資産の傾き」

market return を control し、Narrative 変化に対する感応度を推定する

$$r_{e,i,w}^e = \alpha + \beta^M r_{eM,w}^e + \beta^N \Delta I_{n,w} + \varepsilon_{i,w}$$

asset return



$\Delta$ Intensity

NARR\_01 個別銘柄 mimicking (デモ値)

SHORT 側平均

LONG 側平均



4

long 銘柄

4

short 銘柄

2.000

gross

1.979

beta spread

High-beta 銘柄を long、Low-beta 銘柄を short。gross 2、net 0 の L/S portfolio で Narrative exposure を複製。

# 03：同じ Narrative signal を、3つの実装エンジンで比較する

違いは「Narrative exposure をどの層で表現するか」

## Stock Narrative-mimicking

$$P_t = B_t$$

Intensity  $\Delta$

Stock  $\beta$

Stock weights

- 個別銘柄  $\beta$  で sort
- High  $\beta$  long / Low  $\beta$  short
- gross 2 / net 0

## Raw Theme basket

$$P_t = A_t G_t$$

Narrative

Theme map  $G_t$

Stock weights

- 事前 mapping を使用
- Theme 構成を個別銘柄へ展開
- 原則 long-only / gross 1

## Theme-basket Beta sort

$$P_t = A_t H_t$$

Intensity  $\Delta$

Theme  $\beta$   $H_t$

Stock weights


- Theme return の  $\beta$  で sort
- High  $\beta$  themes long
- Low  $\beta$  themes short

デモ構築結果： raw=28,098 weight rows / stock=11,520 / theme $\beta$ =34,130。利用可能形成月は raw=71、stock=60、theme $\beta$ =65。

# 03： J×K ladder で保有し、 3 方式を同じ土俵で比較

形成期間 J で Narrative を選び、保有期間 K の vintage を重ねる

K=3 の ladder 例



Apr portfolio = active vintages の平均

signal vintage は固定。実装 weight は各月の最新 beta ・最新 theme 構成で更新。

J=6, K=6 Spread performance （synthetic demo）



Return 相関

|        | stock | raw  | themeβ |
|--------|-------|------|--------|
| stock  | 1.00  | 0.25 | 0.24   |
| raw    | 0.25  | 1.00 | 0.15   |
| themeβ | 0.24  | 0.15 | 1.00   |

同じ signal でも実装エンジンが違うと return 相関は低い。

※この performance は synthetic demo であり、実証的な運用成績ではない。

# プレゼンで伝えるべき核：数値が何を意味するか

各 Notebook は「数値の生成プロセス」が異なる。図で対応を固定する。

## 01 発見

記事カード → affinity heatmap → graph

$A_{ij}$ ,  $q_{ij}$ , stability, separation

「同じ話題の島」を見つける

## 02 計測

分類ファネル → 100 件の面積図 → momentum 棒

coverage,  $I^-$ ,  $I^+$ ,  $S_{n,t}$

「どれだけ語られたか」を測る

## 03 運用

beta 散布図 → 3 エンジン → J×K ladder

$\beta^N$ ,  $P_t$ ,  $w_t$ , return

「どう資産で表現するか」を比べる

### 資料作成時の注意

デモ値・説明用値・実データ結果を明示的に分ける。特に 03 の performance は、実データで置き換えるまでは戦略有効性の結論として扱わない。